Tartu Ülikool
Loodus- ja täppisteaduste valdkond
Matemaatika ja statistika instituut

Anna Tšigrinski

Suitsetamise ja lühikese une vaheline seos

Projekt aines MTMS.01,020 Kvalitatiivsete andmete analüüs

Juhendaja: Märt Möls

Tartu 2026

Sisukord

Sissejuhatus **2**

Andmestiku ülevaade **2**

Andmestiku kirjeldus 2

Andmete töötlemine 3

Analüüs **3**

Suitsetamise ja lühikese une seose uurimine 3

Segavate tunnuste mõju 4

Logistiline regressioonimudel 5

Kokkuvõte **6**

Viited **7**

Lisa 1. R-kood **8**

Sissejuhatus

Uni on inimese tervise ja heaolu seisukohalt üks keskseid tegureid. Liiga lühike une kestus võib olla seotud nii halvema enesetunde, keskendumisraskuste kui ka mitmesuguste terviseriskidega. Samal ajal on teada, et erinevad eluviisiga seotud tegurid, sealhulgas suitsetamine, võivad mõjutada inimese unerežiimi ja une kvaliteeti.

Käesoleva projekti eesmärk on uurida, kas suitsetamine on seotud lühikese unega. Lisaks analüüsitakse, kas see seos püsib ka siis, kui arvesse võtta vastajate sugu ja vanuserühma. Töö käigus kasutatakse kvalitatiivsete andmete analüüsi meetodeid, sealhulgas sagedustabeleid, Fisheri täpset testi, tõepärasuhte testi, šansside suhte hindamist koos usalduspiiridega, Cochran–Mantel–Haenszeli testi ning logistilist regressiooni.

Andmestik

Andmestiku kirjeldus

Analüüsis kasutatud andmestik pärineb küsitlusuuringust "Health and Lifestyle Survey Data" [1]. Andmestiku kirjelduse põhjal koguti andmed näost-näkku intervjuude teel VIT Bhopali ülikoolilinnakus Indias. Tegemist on läbilõikelise uuringuga, kuna kõik tunnused mõõdeti ühe ajahetke seisuga. Valim ei ole juhuvalim, vaid mugavusvalim, mis tähendab, et tulemuste üldistamisel laiemale populatsioonile tuleb olla ettevaatlik.

Andmestikus on algselt 571 vaatlust ja 24 tunnust. Käesolevas töös keskendutakse järgmistele tunnustele:

- **suitsetamine** – kas vastaja suitsetab (jah/ei),
- **uni** – vastaja keskmine une kestus tundides,
- **lühike uni** – tuletatud binaarne tunnus, mille väärtus on `jah`, kui vastaja magab vähem kui 7 tundi ööpäevas, ja `ei`, kui vastaja magab vähemalt 7 tundi,
- **sugu** – mees või naine,
- **vanusegrupp** – vanus jaotatuna rühmadesse 17–24, 25–34 ja 35+.

Andmete töötlemine

Esialgsed tunnusenimed muudeti eestikeelseks. Lisaks puhastati tekstiväärtused, ühtlustati suur- ja väiketähed ning kodeeriti osa tunnuseid ümber.

Tunnus `Gender` kodeeriti ümber tunnuseks `sugu`, kus võimalikud väärtused olid `mees` ja `naine`. Tunnus `Smoking Habit` kodeeriti ümber binaarseks tunnuseks `suitsetamine` väärtustega `jah` ja `ei`.

Tunnus `Age Group` osutus tegelikult vanuseks aastates, mitte vanuserühmaks. Seetõttu moodustati uus tunnus `vanusegrupp`, mille tasemed olid 17–24, 25–34 ja 35+.

Tunnus `Sleep Duration` sisaldas une kestust tekstikujul (näiteks `6 hrs`, `5:30 hrs` ning ka mitte-arvulisi väärtusi nagu `normal`), mistõttu see teisendati arvuliseks tunnuseks `uni_tunnid`. Mitte-arvulised väärtused käsitleti puuduvatena. Selle põhjal moodustati binaarne tunnus `lyhike_uni`, kus väärtus `jah` tähistab vähem kui 7 tundi und ja väärtus `ei` vähemalt 7 tundi und.

Pärast puuduva või sobimatu väärtusega vaatluste eemaldamist jäi põhiandmestikku 569 vaatlust.

Analüüs

Analüüs viidi läbi statistikatarkvara R abil [2].

Suitsetamise ja lühikese une seose uurimine

Kõigepealt uuriti suitsetamise ja lühikese une seost 2×2 sagedustabeli abil. Saadud tulemused on esitatud tabelis 1.

Tabel 1: Suitsetamise ja lühikese une jaotus vastajate seas

	Mitte lühike uni	Lühike uni
Mittesuitsetaja	278	211
Suitsetaja	41	39

Tabelist 1 selgub, et suitsetajate seas on lühikese une osakaal veidi suurem kui mittesuitsetajatel (vastavalt 48,8% ja 43,1%). Sama muster on nähtav ka joonisel 1.

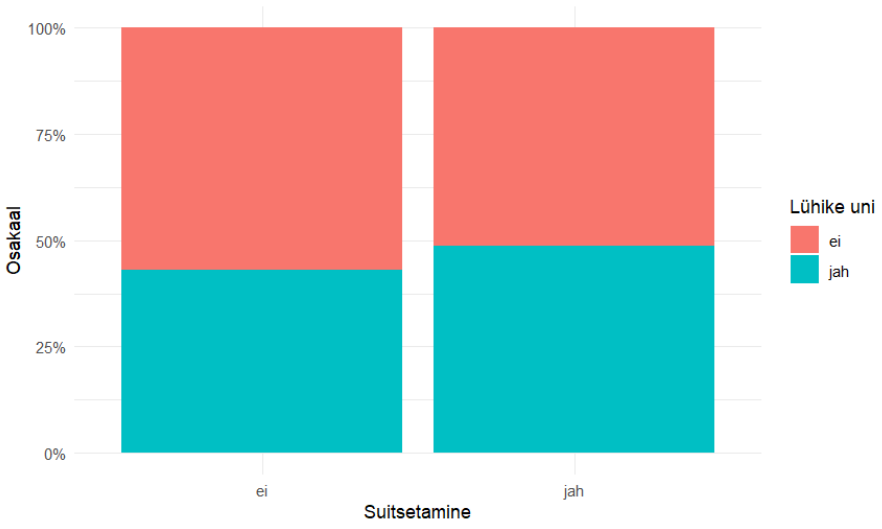

Joonis 1: Lühikese une osakaal suitsetamise järgi

Seose statistiliseks kontrollimiseks kasutati Fisheri täpset testi ning tõepärasuhte testi. Fisheri testi p-väärtus oli 0,395 ja tõepärasuhte testi p-väärtus 0,351. Kuna mõlema testi p-väärtused on suuremad kui 0,05, ei ole alust nullhüpoteesi tagasi lükata. Seega ei ilmne lihtsas 2×2 tabelis suitsetamise ja lühikese une vahel statistiliselt olulist seost, mis viitab sellele, et toorandmete põhjal ei ole nende tunnuste vahel selget seost.

Seose tugevuse iseloomustamiseks hinnati šansside suhe. Saadi hinnang OR = 1,253, mille 95% usaldusvahemik oli 0,778 kuni 2,016. Kuna usaldusvahemik sisaldab väärtust 1, ei saa selle põhjal väita, et suitsetajate ja mittesuitsetajate lühikese une šansid erineksid statistiliselt oluliselt. Seega võib järeldada, et suitsetamise ja lühikese une vahel ei ole lihtsas analüüsis statistiliselt olulist seost.

Segavate tunnuste mõju

Järgmisena uuriti, kas sugu või vanus võivad olla segavad tunnused suitsetamise ja lühikese une vahelises seoses.

Tabel 2: Suitsetajate ja mittesuitsetajate jaotus vanuserühmade järgi

	17–24	25–34	35+
Mittesuitsetaja	167	141	181
Suitsetaja	19	60	1

Nagu on näha tabelist 2, on suitsetajate ja mittesuitsetajate vanuseline jaotus märkimisväärselt

erinev. Suitsetajad kuuluvad valdavalt vanuserühma 25–34, samas kui vanuserühmas 35+ on neid väga vähe.

Esmalt viidi läbi Cochran–Mantel–Haenszeli test soo järgi tinglikustades. Saadud p-väärtus oli 0,418 ning ühise šansside suhte hinnang 1,25 koos 95% usaldusvahemikuga 0,780 kuni 2,012. See tulemus oli väga sarnane lihtsa 2×2 tabeli põhjal saadud tulemusele, mistõttu võib järeldada, et sugu ei ole antud seoses oluline segav tunnus.

Seejärel uuriti vanuserühmade mõju. Selgus, et suitsetajate ja mittesuitsetajate vanuseline jaotus oli üsna erinev. Mittesuitsetajatest 34,2% kuulus vanuserühma 17–24, 28,8% vanuserühma 25–34 ning 37,0% vanuserühma 35+. Suitsetajatest seevastu kuulus 23,8% vanuserühma 17–24, koguni 75,0% vanuserühma 25–34 ning vaid 1,3% vanuserühma 35+.

See viitab sellele, et suitsetajad ja mittesuitsetajad ei ole vanuse poolest võrreldavad rühmad ning vanus võib olla segav tunnus. Selle kontrollimiseks kasutati Cochran–Mantel–Haenszeli testi vanuserühmade järgi tinglikustades. Tulemuseks saadi p-väärtus 0,000659 ja ühise šansside suhte hinnang 2,451, mille 95% usaldusvahemik oli 1,455 kuni 4,129.

Seega selgus, et sama vanuserühma piires oli suitsetajatel lühikese une šanss ligikaudu 2,5 korda suurem kui mittesuitsetajatel. Võrreldes lihtsa 2×2 tabeliga on tulemus siin märksa tugevam, mis kinnitab, et vanus on antud seoses oluline segav tunnus.

Logistiline regressioonimudel

Logistilise regressiooni tulemused on esitatud tabelis 3.

Tabel 3: Logistilise regressioonimudeli šansside suhted ja 95% usalduspiirid

Tunnus	OR	Alumine piir	Ülemine piir
Suitsetamine: jah	2,558	1,510	4,358
Sugu: naine	1,031	0,723	1,470
Vanusegrupp: 25–34	0,626	0,397	0,979
Vanusegrupp: 35+	3,702	2,410	5,743

Andmete kirjeldamiseks kasutati logistilist regressioonimudelit, kuna vastustunnus `lyhike_uni` on binaarne ning see mudel võimaldab hinnata seletavate tunnuste mõju lühikese une šansile. Mudelisse kaasati seletavate tunnustena suitsetamine, sugu ja vanusegrupp.

Logistilise regressiooni tulemused näitasid, et suitsetamine on statistiliselt oluline tunnus ($p =$

0,000496). Suitsetajate lühikese une šanss oli hinnanguliselt $OR = 2{,}558$ (95% usaldusintervall 1,510 kuni 4,358). See tähendab, et sama soo ja vanuserühma piires oli suitsetajatel ligikaudu 2,6 korda suurem lühikese une šanss kui mittesuitsetajatel.

Tunnus sugu ei osutunud statistiliselt oluliseks ($p = 0{,}865$), mis on kooskõlas varasema Cochran–Mantel–Haenszeli testi tulemusega. Vanuserühmal oli aga oluline mõju.

Lisaks võrreldi kahte logistilist regressioonimudelit. Deviantsuse analüüs näitas, et suitsetamise lisamine parandab mudelit statistiliselt oluliselt ($\Delta D = 12{,}166$, $p = 0{,}00049$).

Kokkuvõte

Käesolevas töös uuriti suitsetamise ja lühikese une vahelist seost läbilõikelise küsitlusuuringu andmete põhjal. Esialgne 2×2 sagedustabel ei näidanud suitsetamise ja lühikese une vahel statistiliselt olulist seost. Samas selgus edasisel analüüsil, et vanus mõjutab seda seost tugevalt.

Soo järgi tinglikustamine ei muutnud tulemusi, mistõttu sugu ei osutunud oluliseks segavaks tunnuseks. Vanuserühmade järgi tinglikustamisel ilmnes aga selge seos: sama vanuserühma piires oli suitsetajatel lühikese une šanss ligikaudu 2,5 korda suurem kui mittesuitsetajatel. Seda kinnitas ka logistiline regressioonimudel, mille põhjal oli suitsetamise mõju statistiliselt oluline ka pärast soo ja vanuse arvesse võtmist.

Seega võib järeldada, et kuigi toorandmete põhjal ei paistnud suitsetamise ja lühikese une vahel tugev seos, muutub see seos nähtavaks pärast vanuse arvesse võtmist. Töö näitas hästi, kui oluline on kvalitatiivsete andmete analüüsis arvestada võimalike segavate tunnustega ning mitte piirduda üksnes lihtsate sagedustabelitega.

Viited

[1] Maurya, J. P., Mathur, P., Patil, U., Thakur, A., Gawai, A., ja Daflapurkar, A. *Health and Lifestyle Survey Data*. Mendeley Data, Version 1, 2025. DOI: 10.17632/6622pm2t95.1. Kättesaadav: https://data.mendeley.com/datasets/6622pm2t95/1

[2] R Core Team. *R: A Language and Environment for Statistical Computing*. R Foundation for Statistical Computing, Vienna, Austria, 2024. https://www.R-project.org/

Lisa 1. R-kood

```r
library(dplyr)
library(stringr)
library(readr)
library(forcats)
library(DescTools)
library(epitools)
library(pROC)
library(ggplot2)

# andmete sisselugemine
andmed <- read.csv(
  file = "C:/Users/Kakumäe/OneDrive/Desktop/AnnaK/dataset.csv",
  fileEncoding = "UTF-8"
)

# tunnuste nimide vahetus eesti keelde
andmed <- andmed %>%
  rename(
    sugu = Gender,
    vanus = Age.Group,
    suitsetamine = Smoking.Habit,
    uni = Sleep.Duration
  )

# tekstide puhastus
andmed <- andmed %>%
  mutate(across(where(is.character), ~ str_trim(str_to_lower(.x))))

# sugu
andmed <- andmed %>%
  mutate(
    sugu = case_when(
      sugu %in% c("m", "male") ~ "mees",
      sugu %in% c("f", "female") ~ "naine",
      TRUE ~ NA_character_
    )
  )

# vanus ja vanusegrupp
```

```r
andmed <- andmed %>%
  mutate(
    vanus = as.numeric(vanus),
    vanusegrupp = case_when(
      vanus >= 17 & vanus <= 24 ~ "17-24",
      vanus >= 25 & vanus <= 34 ~ "25-34",
      vanus >= 35 ~ "35+",
      TRUE ~ NA_character_
    )
  )

# suitsetamine
andmed <- andmed %>%
  mutate(
    suitsetamine = case_when(
      suitsetamine %in% c("yes", "y") ~ "jah",
      suitsetamine %in% c("no", "n") ~ "ei",
      TRUE ~ NA_character_
    )
  )

# une kestuse teisendamine arvuliseks
uni_parandus <- function(x) {
  x <- str_trim(str_to_lower(x))
  x <- str_replace_all(x, "hrs|hr|hours|hour", "")
  x <- str_trim(x)

  sapply(x, function(val) {
    if (is.na(val) || val == "") return(NA_real_)

    if (str_detect(val, ":")) {
      parts <- str_split(val, ":", simplify = TRUE)
      h <- suppressWarnings(as.numeric(parts[1]))
      m <- suppressWarnings(as.numeric(parts[2]))
      return(h + m / 60)
    }

    return(suppressWarnings(as.numeric(val)))
  })
}
```

```r

andmed <- andmed %>%
  mutate(
    uni_tunnid = uni_parandus(uni),
    lyhike_uni = case_when(
      uni_tunnid < 7 ~ "jah",
      uni_tunnid >= 7 ~ "ei",
      TRUE ~ NA_character_
    )
  )

# puhas analüüsiandmestik
puhas_andmed <- andmed %>%
  select(
    sugu,
    vanus,
    vanusegrupp,
    suitsetamine,
    uni_tunnid,
    lyhike_uni
  ) %>%
  filter(
    !is.na(sugu),
    !is.na(vanusegrupp),
    !is.na(suitsetamine),
    !is.na(lyhike_uni)
  ) %>%
  mutate(
    sugu = factor(sugu),
    vanusegrupp = factor(vanusegrupp, levels = c("17-24", "25-34", "35+")),
    suitsetamine = factor(suitsetamine, levels = c("ei", "jah")),
    lyhike_uni = factor(lyhike_uni, levels = c("ei", "jah"))
  )

table(puhas_andmed$vanusegrupp)
prop.table(table(puhas_andmed$vanusegrupp))
table(puhas_andmed$suitsetamine, puhas_andmed$lyhike_uni)

# reaprotsendid
prop.table(table(puhas_andmed$suitsetamine, puhas_andmed$lyhike_uni), 1)
```

```r

# Fisheri täpne test
fisher.test(table(puhas_andmed$suitsetamine, puhas_andmed$lyhike_uni))

# G-test
GTest(table(puhas_andmed$suitsetamine, puhas_andmed$lyhike_uni))

# šansside suhe ja 95% usaldusvahemik
oddsratio(table(puhas_andmed$suitsetamine, puhas_andmed$lyhike_uni))

# sagedustabelid soo kaupa
table(puhas_andmed$suitsetamine, puhas_andmed$lyhike_uni, puhas_andmed$sugu)

# Cochran-Mantel-Haenszeli test
mantelhaen.test(table(
  puhas_andmed$suitsetamine,
  puhas_andmed$lyhike_uni,
  puhas_andmed$sugu
))

# logistiline regressioon
m1 <- glm(
  lyhike_uni ~ suitsetamine + sugu + vanusegrupp,
  family = binomial(),
  data = puhas_andmed
)

summary(m1)

# OR-id ja 95% usalduspiirid
exp(cbind(OR = coef(m1), confint(m1)))

table(puhas_andmed$suitsetamine, puhas_andmed$vanusegrupp)
prop.table(table(puhas_andmed$suitsetamine, puhas_andmed$vanusegrupp), 1)

mantelhaen.test(table(
  puhas_andmed$suitsetamine,
  puhas_andmed$lyhike_uni,
  puhas_andmed$vanusegrupp
))
```

```r

# mudelite võrdlus
m0 <- glm(
  lyhike_uni ~ sugu + vanusegrupp,
  family = binomial(),
  data = puhas_andmed
)

m1 <- glm(
  lyhike_uni ~ suitsetamine + sugu + vanusegrupp,
  family = binomial(),
  data = puhas_andmed
)

anova(m0, m1, test = "Chisq")

# joonis
joonis <- puhas_andmed %>%
  group_by(suitsetamine, lyhike_uni) %>%
  summarise(n = n(), .groups = "drop") %>%
  group_by(suitsetamine) %>%
  mutate(prop = n / sum(n))

ggplot(joonis, aes(x = suitsetamine, y = prop, fill = lyhike_uni)) +
  geom_col(position = "fill") +
  labs(
    x = "Suitsetamine",
    y = "Osakaal",
    fill = "Lühike uni"
  ) +
  scale_y_continuous(labels = scales::percent) +
  theme_minimal()
```